

最优化方法-习题解答

张彦斌

计算机学院
2015年12月21日

Contents

1 第一章最优化理论基础-P13习题1(1)、2(4)、3、4	2
2 第二章线搜索算法-P27习题2、4、6	4
2.1 第2题	4
2.2 第4题	6
2.3 第6题	6
3 第三章最速下降法和牛顿法P41习题4, 5, 7	8
3.1 第4题	8
3.2 第5题	10
3.3 第7题	11
4 第四章共轭梯度法P51习题1, 3, 6(1)	11
4.1 第1题	11
4.2 第3题	11
4.3 第6(1)题	12
5 第七章非线性最小二乘问题P98-1, 2	13
5.1 第1题	13
5.2 第2题	14
5.3 第4题	15
5.4 第6题	15
6 第八章最优性条件P112-1, 2	19
6.1 第1题	19
6.2 第2题	19
6.3 第5题	20
6.4 第6题	21
7 最优控制法[习题1、2]	22
7.1 习题1:	22
7.2 习题2:	23

8	第九章罚函数法P132, 1-(1)、2-(1)、3-(3),6	24
8.1	习题1(1)	24
8.2	习题2(1)	25
8.3	习题3(1)	27
9	第十一章二次规划习题11 P178-1 (1), 5	28
9.1	习题1	28
9.2	习题5	29

1 第一章最优化理论基础-P13习题1(1)、2(4)、3、4

1.验证下列各集合是凸集:

$$(1) S = \{(x_1, x_2) | 2x_1 + x_2 \geq 1, x_1 - 2x_2 \geq 1\};$$

需要验证:

根据凸集的定义, 对任意的 $x(x_1, x_2), y(y_1, y_2) \in S$ 及任意的实数 $\lambda \in [0, 1]$, 都有 $\lambda x + (1 - \lambda)y \in S$.

即, $(\lambda x_1 + (1 - \lambda)y_1, \lambda x_2 + (1 - \lambda)y_2) \in S$

证: 由 $x(x_1, x_2), y(y_1, y_2) \in S$ 得到,

$$\begin{cases} 2x_1 + x_2 \geq 1, x_1 - 2x_2 \geq 1 \\ 2y_1 + y_2 \geq 1, y_1 - 2y_2 \geq 1 \end{cases} \quad (1)$$

把(1)中的两个式子对应的左右两部分分别乘以 λ 和 $1 - \lambda$, 然后再相加, 即得

$$\begin{aligned} \lambda(2x_1 + x_2) + (1 - \lambda)(2y_1 + y_2) &\geq 1, \\ \lambda(x_1 - 2x_2) + (1 - \lambda)(y_1 - 2y_2) &\geq 1 \end{aligned} \quad (2)$$

合并同类项,

$$\begin{aligned} 2(\lambda x_1 + (1 - \lambda)y_1) + (\lambda x_2 + (1 - \lambda)y_2) &\geq 1, \\ (\lambda x_1 + (1 - \lambda)y_1) - 2(\lambda x_2 + (1 - \lambda)y_2) &\geq 1 \end{aligned} \quad (3)$$

证毕.

2.判断下列函数为凸(凹)函数或严格凸(凹)函数:

$$(4) f(x) = 2x_1^2 + x_2^2 + 2x_3^2 + x_1x_2 - 3x_1x_3 + x_1 - x_3$$

首先二阶导数连续可微, 根据定理1.5, f 在凸集上是

(I) 凸函数的充分必要条件是 $\nabla^2 f(x)$ 对一切 x 为半正定;

(II) 严格凸函数的充分条件是 $\nabla^2 f(x)$ 对一切 x 为正定。

$$\nabla^2 f(x) = \begin{pmatrix} 4 & 1 & -3 \\ 1 & 2 & 0 \\ -3 & 0 & 4 \end{pmatrix} \quad (4)$$

正定矩阵

说明为什么是正定矩阵?

3. 证明 $f(x) = \frac{1}{2}x^T Gx + b^T x$ 为严格凸函数当且仅当 Hesse 矩阵 G 正定。

证明: 根据严格凸函数定义证明。

对任意 $x \neq y$, 及任意实数 $\lambda \in (0, 1)$ 都有 $f(\lambda x + (1-\lambda)y) < \lambda f(x) + (1-\lambda)f(y)$ 。

充分性: Hesse 矩阵 G 正定 \Rightarrow 严格凸函数。

$$f(\lambda x + (1-\lambda)y) = \frac{1}{2}(\lambda x + (1-\lambda)y)^T G(\lambda x + (1-\lambda)y) + b^T(\lambda x + (1-\lambda)y)$$

$$\lambda f(x) + (1-\lambda)f(y) = \lambda(\frac{1}{2}x^T Gx + b^T x) + (1-\lambda)(\frac{1}{2}y^T Gy + b^T y)$$

$$\begin{aligned} \lambda f(x) + (1-\lambda)f(y) - f(\lambda x + (1-\lambda)y) &= \lambda(\frac{1}{2}x^T Gx) + (1-\lambda)(\frac{1}{2}y^T Gy) - \\ &[\frac{1}{2}(\lambda x)^T G(\lambda x) + \frac{1}{2}(1-\lambda)y^T G(1-\lambda)y + \frac{1}{2}\lambda x^T G(1-\lambda)y + \frac{1}{2}(1-\lambda)y^T G\lambda x] \\ &= \frac{1}{2}\lambda x^T G(1-\lambda)x + \frac{1}{2}(1-\lambda)y^T G\lambda y - \frac{1}{2}\lambda x^T G(1-\lambda)y - \frac{1}{2}(1-\lambda)y^T G\lambda x \\ &= \frac{1}{2}\lambda x^T G(1-\lambda)(x-y) + \frac{1}{2}(1-\lambda)y^T G\lambda(y-x) \\ &= \frac{1}{2}\lambda(1-\lambda)(x-y)^T G(x-y) > 0 \end{aligned}$$

反之, 必要性: 严格凸函数 \Rightarrow Hesse 矩阵 G 正定。

类似, 当对任意 $x \neq y$, 及任意实数 $\lambda \in (0, 1)$ 都有 $f(\lambda x + (1-\lambda)y) < \lambda f(x) + (1-\lambda)f(y)$ 。

$$\begin{aligned} \lambda f(x) + (1-\lambda)f(y) - f(\lambda x + (1-\lambda)y) &= \lambda(\frac{1}{2}x^T Gx) + (1-\lambda)(\frac{1}{2}y^T Gy) - \\ &[\frac{1}{2}(\lambda x)^T G(\lambda x) + \frac{1}{2}(1-\lambda)y^T G(1-\lambda)y + \frac{1}{2}\lambda x^T G(1-\lambda)y + \frac{1}{2}(1-\lambda)y^T G\lambda x] \\ &= \frac{1}{2}\lambda x^T G(1-\lambda)x + \frac{1}{2}(1-\lambda)y^T G\lambda y - \frac{1}{2}\lambda x^T G(1-\lambda)y - \frac{1}{2}(1-\lambda)y^T G\lambda x \\ &= \frac{1}{2}\lambda x^T G(1-\lambda)(x-y) + \frac{1}{2}(1-\lambda)y^T G\lambda(y-x) \\ &= \frac{1}{2}\lambda(1-\lambda)(x-y)^T G(x-y) > 0 \end{aligned}$$

4. 若对任意 $x \in \mathbb{R}^n$ 及实数 $\theta > 0$ 都有 $f(\theta x) = \theta f(x)$, 证明 $f(x)$ 在 \mathbb{R}^n 上为凸函数的充要条件是 $\forall x, y \in \mathbb{R}^n, f(x+y) \leq f(x) + f(y)$

证明: 根据严格凸函数定义证明。

定义: 对任意 $x \neq y$, 及任意实数 $\lambda \in (0, 1)$ 都有 $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$ 。

充分条件: $\forall x, y \in \mathbb{R}^n$, 有 $f(x+y) \leq f(x) + f(y)$

对任意 $x \neq y$, 及任意实数 $\lambda \in (0, 1)$ 都有 $f(\lambda x + (1-\lambda)y) \leq f(\lambda x) + f((1-\lambda)y)$

利用 $f(\theta x) = \theta f(x)$,

$$f(\lambda x + (1 - \lambda)y) \leq f(\lambda x) + f((1 - \lambda)y) = \lambda f(x) + (1 - \lambda)f(y).$$

充分性证毕;

$$\text{必要性: } f(x) \text{ 在 } \mathbb{R}^n \text{ 上为凸函数} \Rightarrow \forall x, y \in \mathbb{R}^n, f(x + y) \leq f(x) + f(y)$$

根据定义有对任意 $x \neq y$, 及任意实数 $\lambda \in (0, 1)$ 都有 $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$.

$$\text{不妨取 } \lambda = \frac{1}{2}, \text{ 则} \\ f(\frac{1}{2}x + (1 - \frac{1}{2})y) \leq \frac{1}{2}f(x) + (1 - \frac{1}{2})f(y).$$

$$\text{利用 } f(\theta x) = \theta f(x),$$

$$f(\frac{1}{2}(x + y)) = \frac{1}{2}f(x + y) \leq \frac{1}{2}(f(x) + f(y))$$

$$\forall x, y \in \mathbb{R}^n, f(x + y) \leq f(x) + f(y)$$

证毕!

2 第二章线搜索算法-P27习题2、4、6

2.1 第2题

黄金0.618算法:

```
function [s,phis,k,G,E]=golds(phi,a,b,delta,epsilon)

%输入: phi是目标函数, a, b是搜索区间的两个端点

% delta, epsilon分别是自变量和函数值的容许误差

%输出: s, phis 分别是近似极小点和极大值, G是  $n \times 4$  矩阵,

% 其第k行分别是a,p,q,b的第k次迭代值  $a_k, p_k, q_k, b_k$ ,

%  $E = [ds, dphi]$ , 分别是s和phis的误差限

%%%%%%%%%%%%%%

t=(sqrt(5)-1)/2; h=b-a;

phia=feval(phi,a); phib=feval(phi,b);
```

```

p=a+(1-t)*h; q=a+t*h; phip=feval(phi,p); phiq=feval(phi,q);
k=1; G(k,:)=[a, p, q, b];
while(abs(phib-phia)>epsilon)|(h>delta)
if(phip<phiq)
b=q; phib=phiq; q=p; phiq=phip;
h=b-a; p=a+(1-t)*h; phip=feval(phi,p);
else
a=p; phia=phip; p=q; phip=phiq;
h=b-a; q=a+t*h; phiq=feval(phi,q);
end
k=k+1; G(k,:)=[a, p, q, b];
end
ds=abs(b-a); dphi=abs(phib-phia);
if(phip<=phiq)
s=p; phis=phip;
else
s=q; phis=phiq;
end
E=[ds,dphi];
运行: [s,phis,k,G,E] = golds(inline('s^3 - 2 * s + 1'),0,3,0.15,0.01);
结果
ak,pk,qk,bk

```

0	1.1459	1.8541	3.0000
0	0.7082	1.1459	1.8541
0	0.4377	0.7082	1.1459
0.4377	0.7082	0.8754	1.1459
0.7082	0.8754	0.9787	1.1459
0.7082	0.8115	0.8754	0.9787
0.7082	0.7721	0.8115	0.8754
0.7721	0.8115	0.8359	0.8754

(5)

$$[s,phis,k,G,E] = golds(inline('s^3 - 2 * s + 1'), 0, 3, 0.15, 0.001);$$

$$\gg G$$

$$G =$$

0	1.1459	1.8541	3.0000
0	0.7082	1.1459	1.8541
0	0.4377	0.7082	1.1459
0.4377	0.7082	0.8754	1.1459
0.7082	0.8754	0.9787	1.1459
0.7082	0.8115	0.8754	0.9787
0.7082	0.7721	0.8115	0.8754
0.7721	0.8115	0.8359	0.8754
0.7721	0.7965	0.8115	0.8359
0.7965	0.8115	0.8208	0.8359

(6)

2.2 第4题

$$\gg \text{clear all}; [s,phis,k,ds,dphi,S] = qmin(inline('s^3-2*s+1'), 0, 3, 1e-2, 1e-4);$$

$$\gg s$$

$$s =$$

$$0.8165$$

2.3 第6题

$$\text{function f=fun(x)}$$

$$f = 100 * (x(2) - x(1)^2)^2 + (1 - x(1))^2;$$

```

function gf=gfun(x)

gf = [-400 * (x(2) - x(1)^2) * x(1) - 2 * (1 - x(1)), 200 * (x(2) - x(1)^2)]';

function mk=armijo(xk,dk )

beta=0.5; sigma=0.2;

m=0; mmax=20;

while (m<=mmax)

if (fun(xk + beta^m * dk) <= fun(xk) + sigma * beta^m * gfun(xk)' * dk)

mk=m; break;

end

m=m+1;

end

alpha=beta^mk

newxk=xk+alpha*dk

fk=fun(xk)

newfk=fun(newxk)

clear all;xk=[-1,1]';dk=[1,1]';mk=armijo(xk,dk)

alpha =

0.0020

newxk =

-0.9980
1.0020

fk =

4

```

newfk =

3.9956

mk =

9

3 第三章最速下降法和牛顿法P41习题4, 5, 7

3.1 第4题

```
function f=funRosenbrock(x)
```

$$f = 100 * (x(2) - x(1)^2)^2 + (x(1) - 1)^2;$$

```
function gf=gfunRosenbrock(x)
```

$$gf = [-400 * x(1) * (x(2) - x(1)^2) + 2 * (x(1) - 1), 200 * (x(2) - x(1)^2)]';$$

```
function He=HessRosenbrock(x)
```

```
n=length(x);
```

```
He=zeros(n,n);
```

$$He = [1200 * x(1)^2 - 400 * x(2) + 2, -400 * x(1);$$
$$-400 * x(1), 200];$$

```
>> clear all;x0=[-1,2.1]';[x val k]=dampnm('funRosenbrock','gfunRosenbrock','HessRosenbrock',x0)
```

x =

0.999999917104049

0.999999819231277

val =

2.930227376149613e-014

k =

20

初值变换

```
>> clear all;x0=[-1.2,1]';[x val k]=dampnm('funRosenbrock','gfunRosenbrock','HessRosenbrock',x0)
```

x =

0.999999999964320

0.999999999926145

val =

1.895465159084372e-021

k =

22

与最速下降法比较：迭代次数多。

```
>> x0=[-1.2,1]';[x val k]=grad('funRosenbrock','gfunRosenbrock',x0)
```

x =

0.999989060890510

0.999978079102611

val =

1.198472839392700e-010

k =

1435

```
初值变>> x0=[-1,2.1]';[x val k]=grad('funRosenbrock','gfunRosenbrock',x0)
```

x =

0.999989152451513

0.999978260000300

val =

1.178719917790613e-010

k =

426

3.2 第5题

设二次函数为 $f(x) = \frac{1}{2}x^T Hx + b^T x$, 其中 H 为 n 阶对称正定矩阵。证明最速下降法求 $f(x)$ 的极小点时, 序列 x_k 由 $x_{k+1} = x_k - \frac{g_k^T g_k}{g_k^T H g_k} g_k (k = 0, 1, 2, \dots)$ 确立, 其中 x_0 为给定的初始点, $g_k = Hx_k + b$.

证明:

回顾一下最速下降算法步骤:

(0) 初始条件给出

(1) 终止条件判定

(2) 搜索方向确定, $d_k = -g_k$

(3) 步长因子 α_k 计算 (本质上是单变量函数的最优极值确定)

(4) $x_{k+1} = x_k + \alpha_k d_k$

因此, 需要证明的是步长因子 $\alpha_k = \frac{g_k^T g_k}{g_k^T H g_k}$

步3中步长因子 α_k 的确定既可以使用精确线搜索方法, 也可以使用非精确线搜索算法。在理论上都能保证其全局收敛性。若采用精确线搜索方法, 即

$$f(x_k + \alpha_k d_k) = \min f(x_k + \alpha d_k)$$

那么 α_k 应满足

$$\phi'(\alpha) = \frac{d}{d\alpha} f(x_k + \alpha d_k)|_{\alpha=\alpha_k} = \nabla f(x_k + \alpha_k d_k)^T d_k = 0$$

由 $d_k = -g_k = -\nabla f(x_k)$ 有

$$\nabla f(x_{k+1}) \nabla f(x_k) = 0$$

新点 x_{k+1} 处的梯度与旧点 x_k 处的梯度是正交的, 也就是说, 迭代点列所走的路线是锯齿型的, 故其收敛速度是很缓慢的 (至多是线性收敛速度)。

$$\nabla f(x) = Hx + b,$$

$$(Hx_{k+1} + b)^T (Hx_k + b) = 0$$

$$[H(x_k + \alpha_k(-g_k)) + b]^T (Hx_k + b) = 0$$

$$[Hx_k + b]^T(Hx_k + b) + [H(\alpha_k(-g_k))]^T(Hx_k + b) = 0$$

$$g_k^T g_k + [H(\alpha_k(-g_k))]^T g_k = 0$$

$$\alpha_k = \frac{g_k^T g_k}{g_k^T H g_k} \text{ 证毕}$$

3.3 第7题

给定函数 $f(x) = (6 + x_1 + x_2)^2 + (2 - 3x_1 - 3x_2 - x_1x_2)^2$, 求在点 $\bar{x} = (-4, 6)^T$ 处的最速下降方向和牛顿方向。

解答:

最速下降方向 $d_k = -g_k$,

牛顿方向 $-g_k + G_k d_k = 0$

4 第四章共轭梯度法P51习题1, 3, 6(1)

4.1 第1题

1. 证明向量 $\alpha_1 = (1, 0)^T$ 和 $\alpha_2 = (3, -2)^T$ 关于矩阵

$$A = \begin{pmatrix} 2 & 3 \\ 3 & 5 \end{pmatrix} \quad (7)$$

共轭. 验证 $\alpha_1^T A \alpha_2 = 0$.

4.2 第3题

3. 设 $f(x) = \frac{1}{2}x^T H x + b^T x$, 其中

$$H = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}, b = \begin{pmatrix} 3 \\ 3 \end{pmatrix} \quad (8)$$

(1) 证明 $d_0 = (1, 0)^T$ 与 $d_1 = (-1, 2)^T$ 关于 H 共轭;

(2) 以 $x_0 = (0, 0)^T$ 为初始点, d_0 和 d_1 为搜索方向, 用精确线搜索求 f 的极小点.

验证 (1) $d_0^T H d_1 = 0$. (2) 首先, $g(\vec{X}) = \nabla f(\vec{X}) = H\vec{X} + b =$

$$\begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} 3 \\ 3 \end{pmatrix} \quad (9)$$

用定理4.1, 也就是算法4.1产生的迭代序列, 则每一步迭代点 x_{k+1} 都是 $f(x)$ 在 x_0 和方向 d_0, d_1, \dots, d_k 所张成的线性流形, $S_k = \{x | x = x_0 + \sum_{i=0}^k \alpha_i d_i, \forall \alpha_i\}$ 中的

极小点, 特别地, $x_n = x^* = -G^{-1}b$ 是问题的唯一极小点.

精确线搜索得到步长因子 α_k 具有如下性质, $g_{k+1}^T d_k = 0$.

$$\begin{cases} \vec{X}_{k+1} = \vec{X}_k + \alpha_k d_k \\ g_{k+1}^T d_k = 0 \end{cases} \quad (10)$$

$$\vec{X}_{k+1} = \vec{X}_k + \alpha_k d_k, \text{ 即 } \vec{X}_1 = \vec{X}_0 + \alpha_0 d_0;$$

$$g(\vec{X}_1) = g_1 = g(\vec{X}_1) = H\vec{X}_1 + b, ; g_1^T d_0 = 0$$

$$\alpha_0 = -3/4, \vec{X}_1 = (-3/4, 0)^T, f(\vec{X}_1) = -9/8;$$

同理, 利用(10)迭代, 即

$$\begin{cases} \vec{X}_2 = \vec{X}_1 + \alpha_1 d_1 \\ g_2^T d_1 = 0 \end{cases} \quad (11)$$

$$\alpha_1 = -1/4; \vec{X}_2 = (-1/2, -1/2)^T, f(\vec{X}_2) = -3/2,$$

$$f(\vec{X}_2) < f(\vec{X}_1),$$

定理4.1保证了极小点为 $\vec{X}_2 = (-1/2, -1/2)^T$

4.3 第6(1)题

$$6.(1) f(x) = 4x_1^2 + 4x_2^2 - 4x_1x_2 - 12x_2, \text{ 取初始点 } x_0 = (-0.5, 1)^T;$$

$$g(x) = \nabla f(x) = Gx + b, G(x) = \nabla^2 f(x) = G;$$

共轭方向的构造过程, 取初始方向 $d_0 = -g_0$, 令 $x_1 = x_0 + \alpha_0 d_0$, 其中 $\nabla f(x_1)^T d_0 = g_1^T d_0 = 0$, 在 x_1 处, 用 f 在 x_1 的负梯度方向 $-g_1$ 与 d_0 的组合来生成 d_1 , 即 $d_1 = -g_1 + \beta_0 d_0$, 然后选取系数 β_0 , 使得 d_1 与 d_0 关于 G 共轭, 即令 $d_1^T G d_0 = 0$ 确定 β_0 . 因此, $\beta_0 = \frac{g_1^T G d_0}{d_0^T G d_0}; g_1 - g_0 = G(x_1 - x_0) = \alpha_0 G d_0$,

利用定理4.1可知 $g_2^T d_i = 0 (i = 0, 1)$

计算过程:

$$g(x) = Gx + b = \begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} 0 \\ -12 \end{pmatrix} \quad (12)$$

$$G = \begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \quad (13)$$

$$d_0 = -g(x_0) = -Gx - b = -\begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} -0.5 \\ 1 \end{pmatrix} - \begin{pmatrix} 0 \\ -12 \end{pmatrix} = \begin{pmatrix} 8 \\ 2 \end{pmatrix} \quad (14)$$

$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix} -0.5 \\ 1 \end{pmatrix} + \alpha_0 \begin{pmatrix} 8 \\ 2 \end{pmatrix} = \begin{pmatrix} 8\alpha_0 - 0.5 \\ 2\alpha_0 + 1 \end{pmatrix} \quad (15)$$

$$\nabla f(x_1)^T d_0 = g_1^T d_0 = 0$$

$$g_1^T d_0 = \left[\begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} 8\alpha_0 - 0.5 \\ 2\alpha_0 + 1 \end{pmatrix} + \begin{pmatrix} 0 \\ -12 \end{pmatrix} \right]^T \begin{pmatrix} 8 \\ 2 \end{pmatrix} = 0 \quad (16)$$

$$\alpha_0 = 17/104, x_1 = (21/26, 69/52)^T \approx (0.80769, 1.32692)^T$$

$$g_1 = (15/13, -60/13)^T$$

$$\beta_0 = \frac{g_1^T G d_0}{d_0^T G d_0} = 225/676 \approx 0.33284$$

$$d_1 = -g_1 + \beta_0 d_0 = (3315/2197, 23205/4394)^T \approx (1.5088757, 5.281065)^T;$$

$$x_2 = x_1 + \alpha_1 d_1; \nabla f(x_2)^T d_1 = g_2^T d_1 = 0$$

$$x_2 = \begin{pmatrix} (255\alpha_1)/169 + 21/26 \\ (1785\alpha_1)/338 + 69/52 \end{pmatrix} \quad (17)$$

$$g_2 = \begin{pmatrix} 15/13 - (1530\alpha_1)/169 \\ (6120\alpha_1)/169 - 60/13 \end{pmatrix} \quad (18)$$

由此可以求出 $\alpha_1 = 0.127450980392157$;

极值点为 $X_2 = (1, 2)^T$;

5 第七章非线性最小二乘问题P98-1, 2

5.1 第1题

1. 设有非线性方程组

$$\begin{aligned} f_1(x) &= x_1^3 - 2x_2^2 - 1 = 0 \\ f_2(x) &= 2x_1 + x_2 - 2 = 0 \end{aligned} \quad (19)$$

(1) 列出求解这个方程组的非线性最小二乘问题的数学模型;

最小二乘问题的数学表达式: $\min_{x \in R^n} f(x) = \frac{1}{2} \|F(x)\|^2 = \frac{1}{2} \sum_{i=1}^m f_i^2(x)$

(2) 写出求解该问题的高斯-牛顿法迭代公式的具体形式:

$$J_k = F'(x(k)) = (\nabla F_1(x(k)), \dots, \nabla F_m(x(k)))^T = \begin{pmatrix} 3x_{1,k}^2 & -4x_{2,k} \\ 2 & 1 \end{pmatrix} \quad (20)$$

$$d_k^{GN} = -[J_k^T J_k]^{-1} J_k^T F(x_k) =$$

$$\left[\begin{pmatrix} 3x_{1,k}^2 & 2 \\ -4x_{2,k} & 1 \end{pmatrix} \begin{pmatrix} 3x_{1,k}^2 & -4x_{2,k} \\ 2 & 1 \end{pmatrix} \right]^{-1} \begin{pmatrix} 3x_{1,k}^2 & 2 \\ -4x_{2,k} & 1 \end{pmatrix} \begin{pmatrix} x_{1,k}^3 - 2x_{2,k}^2 - 1 \\ 2x_{1,k} + x_{2,k} - 2 \end{pmatrix} \quad (21)$$

(3)初始点取为 $x_0 = (2, 2)^T$,迭代三次:

迭代公式:

$$X_{k+1} = X_k + d_k^{GN}$$

$$X_1 = X_0 + d_0^{GN} =$$

$$3.107142857142859$$

$$3.785714285714287$$

$$X_2 = X_1 + d_1^{GN} =$$

$$5.157431640715118$$

$$7.685136718569831$$

$$X_3 = X_2 + d_2^{GN} =$$

$$8.766682264589718$$

$$16.466635470820520$$

5.2 第2题

2.

解答: (1) 测得的 t_1, t_2 和 y 一共5组数据, 分别代入关系式

$$y = \frac{x_1 x_3 t_1}{1 + x_1 t_1 + x_2 t_2} \quad (22)$$

$$\begin{cases} 0.13 = \frac{x_1 x_3}{1+x_1+x_2} \\ 0.22 = \frac{2x_1 x_3}{1+2x_1+x_2} \\ 0.08 = \frac{x_1 x_3}{1+x_1+2x_2} \\ 0.13 = \frac{2x_1 x_3}{1+2x_1+2x_2} \\ 0.19 = \frac{0.1x_1 x_3}{1+0.1x_1} \end{cases} \quad (23)$$

$$\begin{cases} F_1(x) = x_1 x_3 - 0.13(1+x_1+x_2) \\ F_2(x) = 2x_1 x_3 - 0.22(1+2x_1+x_2) \\ F_3(x) = x_1 x_3 - 0.08(1+x_1+2x_2) \\ F_4(x) = 2x_1 x_3 - 0.13(1+2x_1+2x_2) \\ F_5(x) = 0.1x_1 x_3 - 0.19(1+0.1x_1) \end{cases} \quad (24)$$

(1)最小二乘问题模型表示为 $\min_{x \in R^n} f(x) = \frac{1}{2} \|F(x)\|^2 = \frac{1}{2} \sum_{i=1}^m F_i^2(x)$

(2)高斯牛顿迭代公式的具体公式为:

$$d_k^{GN} = -[J_k^T J_k]^{-1} J_k^T F(x_k)$$

5.3 第4题

思路: 求一阶导数和二阶导数, 利用第一章一阶必要条件定理, 局部极小点判断。

首先判断函数f是否为凸函数? or局部凸函数?

求 $\nabla f(x) = 0$ 得出 $(0, -0.5)^T; (1.46557, 2.1479)^T; (\frac{2}{3}, -\frac{7}{54})^T$

判断 $\nabla^2 f(x)$ 在 $(0, -0.5)^T; (1.46557, 2.1479)^T; (\frac{2}{3}, -\frac{7}{54})^T$ 附近是否正定。

5.4 第6题

6.利用LM方法的matlab程序求解 $\min f(x) = \frac{1}{2} \sum_{i=1}^5 r_i^2(x)$

其中

$$\begin{cases} r_1(x) = x_1^2 + x_2^2 + x_3^2 - 1 \\ r_2(x) = x_1 + x_2 + x_3 - 1 \\ r_3(x) = x_1^2 + x_2^2 + (x_3 - 2)^2 - 1 \\ r_4(x) = x_1 + x_2 - x_3 + 1 \\ r_5(x) = x_1^3 + 3x_2^2 + (5x_3 - x_1 + 1)^2 - 36t \end{cases} \quad (25)$$

t为参数, 可取 $t = 0.5, 1, 5$ 等, 注意当 $t = 1$ 时, $x^* = (0, 0, 1)^T$ 是全局极小点, 这时问题为零残量, 比较不同参数的计算效果。

function [x,val,k]=lmm(Fk,JFk,x0)

%功能: 用L-M方法求解非线性方程组: $F(x)=0$

%输入: x0是初始点, Fk, JFk 分别是求 $F(x_k)$ 及 $F'(x_k)$ 的函数

```

%输出: x, val分别是近似解及——F(xk)——的值, k是迭代次数.

maxk=1000; %给出最大迭代次数

 $\rho = 0.55; \sigma = 0.4; \mu_k = \text{norm}(\text{feval}(Fk, x0));$ 

k=0; epsilon=1e-6; n=length(x0);

while(k<maxk)

    fk=feval(Fk,x0); %计算函数值

    jfk=feval(JFk,x0); %计算Jacobi阵

    gk=jfk'*fk;

     $dk = -(jfk' * jfk + \mu_k * \text{eye}(n)) \backslash gk;$  %解方程组Gk*dk=-gk, 计算搜索方向

    if(norm(gk)<epsilon), break; end %检验终止准则

    m=0; mk=0;

    while(m<20) %用Armijo搜索求步长

         $\text{newf} = 0.5 * \text{norm}(\text{feval}(Fk, x0 + \rho^m * dk))^2;$ 

         $\text{oldf} = 0.5 * \text{norm}(\text{feval}(Fk, x0))^2;$ 

         $\text{if}(\text{newf} < \text{oldf} + \sigma * \rho^m * gk' * dk)$ 

            mk=m; break;

        end

        m=m+1;

    end

     $x0 = x0 + \rho^m * dk;$ 

    muk=norm(feval(Fk,x0));

    k=k+1;

end

```



```

x=x0;

val=0.5* $\mu_k^2$ ;

%gval=norm(gfun(x));

%% 目标函数

(I)t=0.5

function y=Fk(x)

     $y(1) = x(1)^2 + x(2)^2 + x(3)^2 - 1$ ;

     $y(2) = x(1) + x(2) + x(3) - 1$ ;

     $y(3) = x(1)^2 + x(2)^2 + (x(3) - 2)^2 - 1$ ;

     $y(4) = x(1) + x(2) - x(3) + 1$ ;

     $y(5) = x(1)^3 + 3 * x(2)^2 + (5 * x(3) - x(1) + 1)^2 - 36 * 0.5$ ;

    y = y(:);

%%%%%% Jacobi 阵 %%%%%%%%%function JF=JFk(x)

JF=[2*x(1), 2*x(2), 2*x(3);

    1, 1, 1;

    2*x(1),2*x(2),2*(x(3)-2);

    1, 1 -1;

    3 * x(1)^2 - 2 * (5 * x(3) - x(1) + 1),6 * x(2),10 * (5 * x(3) - x(1) + 1)];

>>x0 = [1, 1, 1]'; [x, val, k] = lmm('Fk','JFk',x0)

x =

    0.339361063668441

   -0.200183578804671

    0.714384339944574

```

```

val =

    0.486062168183995

k =

    9

(II)t=1;注意，这里 $x^* = (0, 0, 1)^T$ 是全局极小点，这时问题为零残量。
>>clearall; x0 = [1, 1, 1]'; [x, val, k] = lmm('Fk', 'JFk', x0)

x =

   -0.0000000000000080

    0.0000000000000087

    0.9999999999999985

val =

    2.815888304992978e-027

k =

    8

(III)t=5;

>>clearall; x0 = [1, 1, 1]'; [x, val, k] = lmm('Fk', 'JFk', x0)
x =

   -0.490713830929549

    0.103144026198463

    2.384345136824180

val =

    14.450411547247533

k =

    14

```

6 第八章最优性条件P112-1, 2

6.1 第1题

1. 验证 $\bar{x} = (2, 1)^T$ 是否为下列最优化问题的KT点:

$$\begin{aligned} \min \quad & f(x) = (x_1 - 3)^2 + (x_2 - 2)^2 \\ \text{s.t.} \quad & x_1^2 + x_2^2 \leq 5, \\ & x_1 + 2x_2 = 4, \\ & x_1, x_2 \geq 0. \end{aligned} \quad (26)$$

验证: 计算

$$\nabla f(\bar{x}) = \left[\begin{array}{c} 2(x_1 - 3) \\ 2(x_2 - 2) \end{array} \right] \Big|_{x=\bar{x}} = \left[\begin{array}{c} -2 \\ -2 \end{array} \right], \nabla h(\bar{x}) = \left[\begin{array}{c} 1 \\ 2 \end{array} \right] \quad (27)$$

$$\nabla g_1(\bar{x}) = \left[\begin{array}{c} -2x_1 \\ -2x_2 \end{array} \right] = \left[\begin{array}{c} -4 \\ -2 \end{array} \right], \nabla g_2(\bar{x}) = \left[\begin{array}{c} 1 \\ 0 \end{array} \right], \nabla g_3(\bar{x}) = \left[\begin{array}{c} 0 \\ 1 \end{array} \right] \quad (28)$$

令

$$\nabla f(\bar{x}) - \bar{\mu} \nabla h(\bar{x}) - \bar{\lambda}_1 \nabla g_1(\bar{x}) = 0$$

即

$$\left[\begin{array}{c} -2 \\ -2 \end{array} \right] - \bar{\mu} \left[\begin{array}{c} 1 \\ 2 \end{array} \right] - \bar{\lambda}_1 \left[\begin{array}{c} -4 \\ -2 \end{array} \right] - \bar{\lambda}_2 \left[\begin{array}{c} 1 \\ 0 \end{array} \right] - \bar{\lambda}_3 \left[\begin{array}{c} 0 \\ 1 \end{array} \right] = 0 \quad (29)$$

令 $\bar{\lambda}_2 = 0, \bar{\lambda}_3 = 0$, 解得 $\bar{\mu} = -\frac{2}{3}, \bar{\lambda}_1 = \frac{1}{3}$

所以

$$\begin{cases} \nabla f(\bar{x}) - \bar{\mu} \nabla h(\bar{x}) - \sum_{i=1}^3 \bar{\lambda}_i \nabla g_i(\bar{x}) = 0 \\ \bar{\lambda}_i g_i(\bar{x}) = 0, \bar{\lambda}_i \geq 0, i = 1, 2, 3 \end{cases} \quad (30)$$

这表明 \bar{x} 是KT点, $(\bar{x}, (\bar{\mu}, \bar{\lambda}))$ 是KT对, 其中 $\bar{\mu} = -\frac{2}{3}, \bar{\lambda} = (\frac{1}{3}, 0, 0)^T$.

6.2 第2题

2. 对于最优化问题:

$$\begin{aligned} \min \quad & f(x) = 4x_1 - 3x_2 \\ \text{s.t.} \quad & -(x_1 - 3)^2 + x_2 + 1 \geq 0, \\ & 4 - x_1 - x_2 \geq 0, \\ & x_2 + 7 \geq 0. \end{aligned} \quad (31)$$

求满足KT条件的点。

解：类似第1题

$$\nabla f(\bar{x}) = \left[\begin{array}{c} 4 \\ -3 \end{array} \right] \Big|_{x=\bar{x}} = \left[\begin{array}{c} 4 \\ -3 \end{array} \right], \nabla h(\bar{x}) = \left[\begin{array}{c} 0 \\ 0 \end{array} \right] \quad (32)$$

$$\nabla g_1(\bar{x}) = \left[\begin{array}{c} -2(\bar{x}_1 - 3) \\ 1 \end{array} \right], \nabla g_2(\bar{x}) = \left[\begin{array}{c} -1 \\ -1 \end{array} \right], \nabla g_3(\bar{x}) = \left[\begin{array}{c} 0 \\ 1 \end{array} \right] \quad (33)$$

令

$$\begin{cases} \nabla f(\bar{x}) - \bar{\mu} \nabla h(\bar{x}) - \sum_{i=1}^3 \bar{\lambda}_i \nabla g_i(\bar{x}) = 0 \\ \bar{\lambda}_i g_i(\bar{x}) = 0, \bar{\lambda}_i \geq 0, i = 1, 2, 3 \end{cases} \quad (34)$$

即：

$$\begin{cases} \left[\begin{array}{c} 4 \\ -3 \end{array} \right] - \bar{\lambda}_1 \left[\begin{array}{c} -2(\bar{x}_1 - 3) \\ 1 \end{array} \right] - \bar{\lambda}_2 \left[\begin{array}{c} -1 \\ -1 \end{array} \right] - \bar{\lambda}_3 \left[\begin{array}{c} 0 \\ 1 \end{array} \right] = 0 \\ \bar{\lambda}_1 (-(\bar{x}_1 - 3)^2 + \bar{x}_2 + 1) = 0 \\ \bar{\lambda}_2 (4 - \bar{x}_1 - \bar{x}_2) = 0 \\ \bar{\lambda}_3 (\bar{x}_2 + 7) = 0 \\ \bar{\lambda}_i \geq 0, i = 1, 2, 3 \end{cases} \quad (35)$$

取 $\bar{\lambda}_3 = 0$

$$4 - \bar{x}_1 - \bar{x}_2 = 0 \Rightarrow \bar{x}_2 = 4 - \bar{x}_1$$

$$\text{代入 } -(\bar{x}_1 - 3)^2 + \bar{x}_2 + 1 = 0 \Rightarrow$$

$$-(\bar{x}_1 - 3)^2 + 4 - \bar{x}_1 + 1 = 0 \Rightarrow$$

$$\bar{x}_1 = 1 \text{ 或 } \bar{x}_1 = 4$$

当 $\bar{x}_1 = 4$ 时, $\bar{x}_2 = 0, \bar{\lambda}_1 = -7/3, \bar{\lambda}_2 = 2/3$, 不满足 $\bar{\lambda}_i \geq 0$ 舍去;

当 $\bar{x}_1 = 1$ 时, $\bar{x}_2 = 3, \bar{\lambda}_1 = 7/3, \bar{\lambda}_2 = 16/3$, 满足 $\bar{\lambda}_i \geq 0$;

6.3 第5题

5.利用KT条件推出线性规划

$$\begin{aligned} \min \quad & z = c^T x \\ \text{s.t.} \quad & Ax \leq b, \\ & x \geq 0, \end{aligned} \quad (36)$$

的最优化条件。

解:

$$\begin{cases} \nabla f(x) - \sum_{i=1}^2 \lambda_i \nabla g_i(x) = 0 \\ \lambda_i g_i(x) = 0, \lambda_i \geq 0, i = 1, 2 \end{cases} \quad (37)$$

$$\nabla g_1(x) = -A,$$

$$\nabla g_2(x) = I,$$

其拉格朗日函数为

$$L(x, \lambda_1, \lambda_2) = c^T x - \lambda_1^T (b - Ax) - \lambda_2^T x$$

对上述函数关于 x 求极小. 令

$$\nabla_x L(x, \lambda_1, \lambda_2) = c - \lambda_2 + A^T \lambda_1 = 0,$$

$$\text{由(37)} \lambda_2 g_2(x) = \lambda_2 x = 0,$$

$$\text{令} \lambda_2 = 0,$$

因此最优性条件为:

$$\begin{cases} c + A^T \lambda_1 = 0 \\ \lambda_1 (b - Ax) = 0, \lambda_1 \geq 0 \end{cases} \quad (38)$$

6.4 第6题

6.设二次规划

$$\begin{array}{ll} \min & f(x) = \frac{1}{2} x^T H x + c^T x \\ \text{s.t.} & Ax = b, \end{array} \quad (39)$$

其中 H 为 n 阶对称正定矩阵, 矩阵 A 行满秩, 求其最优解并说明解的唯一性。

解:

首先写出该问题的拉格朗日函数为

$$L(x, \lambda) = \frac{1}{2} x^T H x + c^T x - \lambda^T (Ax - b).$$

对上述函数关于 x 求极小. 由于 H 对称正定, 故函数 $L(x, \lambda)$ 关于 x 为凸函数.
令

$$\nabla_x L(x, \lambda) = Hx + c - A^T \lambda = 0,$$

H 对称正定, 以及等式约束条件 $Ax = b$,

$$Hx + c - A^T \lambda = 0,$$

$$x + H^{-1}c - H^{-1}A^T \lambda = 0,$$

$$Ax + AH^{-1}c - AH^{-1}A^T \lambda = 0,$$

$$b + AH^{-1}c - AH^{-1}A^T \lambda = 0,$$

H 对称正定, A 行满秩, 因此, $AH^{-1}A^T$ 可逆 (需要简单证明),

$$\lambda = (AH^{-1}A^T)^{-1}(b + AH^{-1}c),$$

因此有拉格朗日乘子的唯一性解,

也就有了最优解 $x = -H^{-1}c + H^{-1}A^T \lambda$ 的唯一性。

7 最优控制法[习题1、2]

7.1 习题1:

设一阶系统方程为

$$\dot{x}(t) = u(t), x(t_0) = x_0$$

性能指标取为

$$J = \frac{1}{2}cx^2(t_f) + \frac{1}{2} \int_{t_0}^{t_f} u^2(t)dt$$

式中常数 $c > 0, t_0, t_f$ 给定, $x(t_f)$ 自由;
试求使 J 取极小值的最优控制和相应的性能指标.

解: 引进伴随变量 $\lambda(t)$, 构造哈密顿函数

$$H = L(x, \lambda, t) + \lambda(t)f(x, u, t) = \frac{1}{2}u^2 + \lambda u$$

伴随方程:

$$\dot{\lambda}(t) = \frac{\partial H}{\partial x} = 0$$

边界条件:

$$\lambda(t_f) = \frac{\partial [\frac{1}{2}cx^2(t_f)]}{\partial x(t_f)} = cx(t_f)$$

由必要条件:

$$\frac{\partial H}{\partial u} = u + \lambda = 0$$

得

$$u = -\lambda = -cx(t_f)$$

代入求得状态方程为

$$\dot{x}(t) = -cx(t_f)(t - t_0) + x_0$$

令 $t = t_f$, 则有

$$x(t_f) = \frac{x_0}{1 + c(t_f - t_0)}$$

则最优控制

$$u^* = -cx(t_f) = -\frac{cx_0}{1 + c(t_f - t_0)}$$

性能指标:

$$\frac{1}{2}cx^2(t_f) + \frac{1}{2}c^2x^2(t_f)(t_f - t_0) = \frac{1}{2}x^2(t_f)[c + c^2(t_f - t_0)]$$

7.2 习题2:

设二阶系统方程为

$$\dot{x}_1(t) = x_2(t), \dot{x}_2(t) = u(t)$$

性能指标取为

$$J = \frac{1}{2} \int_0^1 u^2(t) dt$$

求系统由已知初始状态 $x_1(0) = 0, x_2(0) = 0$ 在 $t_f = 1$ 转移到目标集 $x_1(1) + x_2(1) = 1$ 且使 J 取极小的最优控制和最优轨迹。

解: 引进伴随变量 $\lambda(t) = [\lambda_1, \lambda_2]^T$, 构造哈密顿函数

$$H = L(x, \lambda, t) + \lambda(t)^T f(x, u, t) = \frac{1}{2}u^2 + \lambda_1 x_2 + \lambda_2 u$$

伴随方程(协态方程):

$$\dot{\lambda}_1(t) = -\frac{\partial H}{\partial x_1} = 0, \dot{\lambda}_2(t) = -\frac{\partial H}{\partial x_2} = -\lambda_1(t)$$

其解

$$\lambda_1(t) = a_1, \lambda_2(t) = -a_1 t + a_2$$

边界条件

$$x_1(0) = 0, x_2(0) = 0, x_1(1) + x_2(1) = 1$$

横截条件:

$$\lambda|_{t=1} = \gamma^T \frac{\partial \psi}{\partial x(t_f)} = \gamma^T [1, 1]^T$$

其中 $\psi = x_1 + x_2 - 1$

由极值必要条件:

$$\frac{\partial H}{\partial u} = u + \lambda_2 = 0$$

得

$$u = -\lambda_2 = a_1 t - a_2$$

代入求得状态方程为

$$\dot{x}_1 = x_2, \dot{x}_2 = u = a_1 t - a_2$$

则有

$$x_1 = \frac{1}{6}a_1 t^3 - \frac{1}{2}a_2 t^2 + a_3 t + a_4$$

$$x_2 = \frac{1}{2}a_1 t^2 - a_2 t + a_3$$

由边界条件 $x_1(0) = 0, x_2(0) = 0, x_1(1) + x_2(1) = 1$, 知道 $a_3 = a_4 = 0, \frac{2}{3}a_1 - \frac{3}{2}a_2 = 1$

由横截条件知 $a_1 = -a_1 + a_2$, 因此 $a_1 = -\frac{3}{7}, a_2 = -\frac{6}{7}$

则最优控制

$$u^* = -\lambda_2 = a_1 t - a_2 = -\frac{3}{7}t + \frac{6}{7}$$

最优轨迹:

$$x_1^* = -\frac{1}{14}t^3 + \frac{3}{7}t^2$$

$$x_2^* = -\frac{3}{14}t^2 + \frac{6}{7}t$$

8 第九章罚函数法 P132, 1-(1)、2-(1)、3-(3), 6

8.1 习题1(1)

1-(1): 用外罚函数法求解下列约束优化问题:

$$\begin{aligned} \min \quad & f(x) = -x_1 - x_2 \\ \text{s.t.} \quad & x_1^2 + x_2^2 = 1, \end{aligned} \quad (40)$$

解:

由等式约束得 $x_2 = \pm\sqrt{1-x_1^2}$, 代入目标函数得到一个无约束的单变量极小化问题

$$\min \phi(x_1) = -x_1 \pm \sqrt{1-x_1^2}$$

其全局极小点为 $x_1 = \sqrt{\frac{1}{2}}$, 从而得到原问题的全局极小点为 $(\sqrt{\frac{1}{2}}, \sqrt{\frac{1}{2}})$.

现在要使构造的罚函数 $P(x)$, 满足

$$P(x) \begin{cases} = 0, & x_1^2 + x_2^2 - 1 = 0 \\ > 0, & x_1^2 + x_2^2 - 1 \neq 0, \end{cases} \quad (41)$$

只要令 $\bar{P}(x) = (x_1^2 + x_2^2 - 1)^2$ 即可. 现在考察目标函数和上述罚函数的组合

$$P(x, \sigma) = f(x) + \bar{P}(x) = -x_1 - x_2 + \sigma \bar{P}(x)$$

其中 $\sigma > 0$ 是充分大的正数, 称为罚因子 (罚参数). 求这个组合函数的极小点. 由

$$\frac{\partial P(x, \sigma)}{\partial x_1} = \frac{\partial P(x, \sigma)}{\partial x_2} = 0,$$

得

$$\begin{cases} -1 + 4\sigma x_1(x_1^2 + x_2^2 - 1) & = 0 \\ -1 + 4\sigma x_2(x_1^2 + x_2^2 - 1) & = 0 \end{cases} \quad (42)$$

由此可得 $x_1 = x_2 \neq 0$, 因此 $x_1(2x_1^2 - 1) = \frac{1}{4\sigma}$, 当 $\sigma \rightarrow \infty, x_1 = 0$ (舍去) 和 $x_1 = \sqrt{\frac{1}{2}}$. 所以 $x_1 = x_2 = \sqrt{\frac{1}{2}}, \min f(x) = -\sqrt{2}$.

8.2 习题2(1)

2-(1). 用内点法求解下列约束优化问题:

(1)

$$\begin{aligned} \min \quad & f(x) = x_1 + x_2 \\ \text{s.t.} \quad & -x_1^2 + x_2 \leq 0, \\ & x_1 \geq 0; \end{aligned} \quad (43)$$

更正

$$\begin{aligned} \min \quad & f(x) = x_1 + x_2 \\ \text{s.t.} \quad & -x_1^2 + x_2 \geq 0, \\ & x_1 \leq 0; \end{aligned} \quad (44)$$

解:

令 $g_1(x) = x_1^2 - x_2, g_2(x) = x_1$, 给出增广目标函数为

$$H(x, \tau) = x_1 + x_2 - \tau(\ln(x_1^2 - x_2) + \ln(x_1))$$

令

$$\begin{cases} \frac{\partial H}{\partial x_1} &= 1 - \frac{2\tau x_1}{x_1^2 - x_2} - \frac{\tau}{x_1} = 0 \\ \frac{\partial H}{\partial x_2} &= 1 + \frac{\tau}{x_1^2 - x_2} = 0 \end{cases} \quad (45)$$

$$x_1^2 - x_2 = -\tau, 1 + 2x_1 - \frac{\tau}{x_1} = 0,$$

$$x_1 = \frac{-1 \pm \sqrt{1+8\tau}}{4},$$

$$\tau \rightarrow 0, x_1 = 0 \text{ 或 } x_1 = -\frac{1}{2}$$

$$x_1^2 - x_2 = -\tau$$

$$x_2 = 0 \text{ 或 } x_2 = \frac{1}{4}$$

$$\text{当 } x_1 = -\frac{1}{2}, x_2 = \frac{1}{4} \text{ 时 } \min f(x) = -\frac{1}{4}.$$

更正

解:

令 $g_1(x) = -(x_1^2 - x_2), g_2(x) = -x_1$, 给出增广目标函数为

$$H(x, \tau) = x_1 + x_2 - \tau(\ln(-x_1^2 + x_2) + \ln(-x_1))$$

令

$$\begin{cases} \frac{\partial H}{\partial x_1} &= 1 + \frac{2\tau x_1}{-x_1^2 + x_2} - \frac{\tau}{x_1} = 0 \\ \frac{\partial H}{\partial x_2} &= 1 - \frac{\tau}{-x_1^2 + x_2} = 0 \end{cases} \quad (46)$$

$$x_1^2 - x_2 = -\tau, 1 + 2x_1 - \frac{\tau}{x_1} = 0,$$

$$x_1 = \frac{-1 \pm \sqrt{1+8\tau}}{4},$$

$$\tau \rightarrow 0, x_1 = 0 \text{ 或 } x_1 = -\frac{1}{2}$$

$$x_1^2 - x_2 = -\tau$$

$$x_2 = 0 \text{ 或 } x_2 = \frac{1}{4}$$

当 $x_1 = -\frac{1}{2}$, $x_2 = \frac{1}{4}$ 时 $\min f(x) = -\frac{1}{4}$.

8.3 习题3(1)

3-(1).用乘子法求解下列问题:

(1)

$$\begin{aligned} \min \quad & f(x) = x_1^2 + x_2^2 \\ \text{s.t.} \quad & x_1 \geq 0; \end{aligned} \quad (47)$$

解:

PHR算法:

我们回到一般约束优化问题(9.28,9.33) (书上), 我们来构造求解(47) 的乘子法. 此时, 增广拉格朗日函数为

$$\psi(x, \mu, \lambda, \sigma) = f(x) - \sum_{i=1}^l \mu_i h_i(x) + \frac{\sigma}{2} \sum_{i=1}^l h_i^2(x) + \frac{1}{2\sigma} \sum_{i=1}^m ([\min\{0, \sigma g_i(x) - \lambda_i\}]^2 - \lambda_i^2)$$

乘子迭代公式为

$$(\mu_{k+1})_i = (\mu_k)_i - \sigma h_i(x_k), i = 1, 2, \dots, l,$$

$$(\lambda_{k+1})_i = \max\{0, (\lambda_k)_i - \sigma g_i(x_k)\}, i = 1, 2, \dots, m.$$

令

$$\beta_k = (\sum_{i=1}^l h_i^2(x_k) + \sum_{i=1}^m [\min\{g_i(x_k), \frac{(\lambda_k)_i}{\sigma}\}]^2)^{\frac{1}{2}}$$

则终止准则为 $\beta_k \leq \varepsilon$

-重要

$$\psi(x, \lambda, \sigma) = f(x) + \frac{1}{2\sigma} ([\min\{0, \sigma x_1 - \lambda_1\}]^2 - \lambda_1^2)$$

令

$$\begin{cases} \frac{\partial \psi}{\partial x_1} &= 2x_1 = 0, \text{ if } (\sigma x_1 - \lambda_1) < 0 \\ &= 2x_1 + (\sigma x_1 - \lambda_1), \text{ if } (\sigma x_1 - \lambda_1) > 0 \\ \frac{\partial \psi}{\partial x_2} &= 2x_2 = 0 \end{cases} \quad (48)$$

——数值方法角度——

取初始点 $x_0 = (0, 0)^T$, $\lambda_1 = 1$, $\sigma_1 = 2$, $\varepsilon = 1e-5$ $x_1 = x_2 = 0$, $\min f(x) = 0$

$$x_1 = \frac{\lambda_1}{2+\sigma}, x_2 = 0; \text{或者 } x_1 = 0, x_2 = 0$$

$$\sigma \rightarrow \infty, x_1 = 0, x_2 = 0; \min f(x) = 0$$

6. 略。

9 第十一章二次规划习题11 P178-1 (1), 5

9.1 习题1

1. 用拉格朗日方法求解下列二次规划问题: (1)

$$\begin{aligned} \min \quad & f(x) = 2x_1^2 + x_2^2 + x_1x_2 - x_1 - x_2, \\ \text{s.t.} \quad & x_1 + x_2 = 1; \end{aligned} \quad (49)$$

首先写出该问题的拉格朗日函数为

$$L(x, \lambda) = \frac{1}{2}x^T Hx + c^T x - \lambda(Ax - 1).$$

$$H = \begin{pmatrix} 4 & 1 \\ 1 & 2 \end{pmatrix}, c = \begin{pmatrix} -1 \\ -1 \end{pmatrix}, A = (1, 1), \quad (50)$$

对上述函数关于 x 求极小. 由于 H 对称正定, 故函数 $L(x, \lambda)$ 关于 x 为凸函数.
令

$$\nabla_x L(x, \lambda) = Hx + c - A^T \lambda = 0,$$

H 对称正定, 以及等式约束条件 $Ax = 1$,

$$\begin{pmatrix} H & -A^T \\ -A & 0 \end{pmatrix} \begin{pmatrix} x \\ \lambda \end{pmatrix} = \begin{pmatrix} -c \\ -1 \end{pmatrix}, \quad (51)$$

$$\begin{pmatrix} 4 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \lambda \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ -1 \end{pmatrix}, \quad (52)$$

解得

$$\begin{pmatrix} x_1 \\ x_2 \\ \lambda \end{pmatrix} = \begin{pmatrix} 1/4 \\ 3/4 \\ 3/4 \end{pmatrix}, \quad (53)$$

9.2 习题5

5. 设 $A \in R^{m \times n}$ 行满秩, $a \in R^n$, 证明二次规划问题

$$\begin{aligned} \min \quad & \frac{1}{2}(x-a)^T(x-a), \\ \text{s.t.} \quad & Ax = b; \end{aligned} \quad (54)$$

的解以及相应的拉格朗日乘子分别为:

$$x^* = a + A^T(AA^T)^{-1}(b - Aa), \lambda^* = (AA^T)^{-1}(b - Aa)$$

证明:

二次规划问题等价于

$$\begin{aligned} \min \quad & \frac{1}{2}x^THx - a^Tx + \frac{1}{2}a^Ta, \\ \text{s.t.} \quad & Ax = b; \end{aligned} \quad (55)$$

其中 H 单位矩阵 E ,

对上述函数关于 x 求极小. 由于 H 对称正定, 故函数 $L(x, \lambda)$ 关于 x 为凸函数.

令

$$\nabla_x L(x, \lambda) = Hx - a - A^T\lambda = 0,$$

H 对称正定, 以及等式约束条件 $Ax = b$,

$$Hx - a - A^T\lambda = 0,$$

$$x + H^{-1}(-a) - H^{-1}A^T\lambda = 0,$$

$$Ax + AH^{-1}(-a) - AH^{-1}A^T\lambda = 0,$$

$$b + AH^{-1}(-a) - AH^{-1}A^T\lambda = 0,$$

其中 H 单位矩阵 E , A 行满秩, 因此, AA^T 可逆 (需要简单证明),

$$\lambda = (AA^T)^{-1}(b - Aa),$$

因此有拉格朗日乘子的唯一性解,

也就有了最优解 $x = -H^{-1}(-a) + H^{-1}A^T\lambda = a + A^T(AA^T)^{-1}(b - Aa)$ 的唯一性。